


Übungsblatt: Backpropagation

NN Backprop. 01: Gewichtsupdates für versteckte Schichten

Gegeben Vorwärtslauf

Für jede Schicht l :

$$Z^{[l]} = W^{[l]} A^{[l-1]} + b^{[l]}, \quad A^{[l]} = g(Z^{[l]})$$

mit $g = \sigma$ und

$$g'(Z^{[l]}) = \sigma(Z^{[l]}) (1 - \sigma(Z^{[l]})) = A^{[l]} (1 - A^{[l]})$$

Netz: $L=1$ (Hidden), $L=2$ (Hidden 2), $L=3$ (Output)

$$A^{[0]} = X$$

Rückwärtslauf

Aus der Vorlesung gelten:

$$(3) dZ^{[l]} = dA^{[l]} * g'(Z^{[l]})$$

$$(4) dW^{[l]} = \frac{1}{m} dZ^{[l]} (A^{[l-1]})^T$$

$$(5) db^{[l]} = \frac{1}{m} \sum_{i=1}^m dZ^{[l]}(i)$$

$$(6) dA^{[l-1]} = (W^{[l]})^T dZ^{[l]}$$

Herleitung für die erste versteckte Schicht $l=1$ (Sigmoid)

Zuerst wird $dA^{[1]}$ aus der nächsten Schicht rückwärts übernommen:

$$dA^{[1]} = (W^{[2]})^T dz^{[2]}$$

Dann folgt mit (3) und Sigmoid ableitung:

$$dz^{[1]} = dA^{[1]} * g'(z^{[1]}) = dA^{[1]} * (A^{[1]}(1-A^{[1]}))$$

Gewichtsgradient mit (4) und $A^{[0]} = X$

$$dW^{[1]} = \frac{1}{m} dz^{[1]} (A^{[0]})^T = \frac{1}{m} dz^{[1]} X^T$$

Bias-Gradient mit (5):

$$db^{[1]} = \frac{1}{m} \sum_{i=1}^m dz^{[1]}(i)$$

Parameterupdate (7)(8):

$$W^{[1]} \leftarrow W^{[1]} - \alpha dW^{[1]}, \quad b^{[1]} \leftarrow b^{[1]} - \alpha db^{[1]}$$

NN. Backprop. 02: Forward- und Backpropagation

Gegeben:

$$\text{Sigmoid } \sigma(z) = \frac{1}{1+e^z}, \sigma(z)(1-\sigma(z))$$

Loss (Fehlerfunktion):

$$J = \frac{1}{2} (y - y^T)^2$$

Eingabe:

$$(x, y^T) = (0, 0.5), \text{ Lernrate } \alpha = 0.01$$

Netzwerk

Hidden-Zelle:

$$- w_x \rightarrow h = -1, \text{ Biasgewicht } w_b \rightarrow h = 1$$

Output-Zelle:

$$- w_h \rightarrow o = 1, w_x \rightarrow o = 2, \text{ Biasgewicht } w_b \rightarrow o = -2$$

Vorwärtslauf: Ausgabe y und Fehler

Hidden:

$$z_1 = (-1) \cdot x + 1 \cdot 1 = 1$$

$$a_1 = \sigma(z_1) = \sigma(1) = 0,7310586$$

Output:

$$z_2 = 1 \cdot a_1 + 2 \cdot x + (-2) \cdot 1 = a_1 - 2 = -1,2689414$$

$$y = \sigma(z_2) = \sigma(-1,2689414) = 0,2194385$$

Fehler:

$$e = y - y^T = 0,2194385 - 0,5 = -0,2805615$$

$$J = \frac{1}{2} e^2 = \frac{1}{2} (-0,2805615)^2 = 0,0393574$$

Partielle Ableitungen und Gewichtsupdates

Output-Schicht

$$\delta_2 = \frac{\partial J}{\partial z_2} = (y - y^T) \cdot y(1 - y)$$

$$y(1 - y) = 0,2194385 \cdot 0,7805615 = 0,1713104$$

$$\delta_2 = (-0,2805615) \cdot 0,1713104 = -0,0480560$$

Gradienten:

$$\frac{\partial J}{\partial w_h \rightarrow 0} = \delta_2 \cdot a_1 = -0,0480560 \cdot 0,7310586 = -0,0351318$$

$$\frac{\partial J}{\partial w_x \rightarrow 0} = \delta_2 \cdot x = -0,0480560 \cdot 0 = 0$$

$$\frac{\partial J}{\partial w_b \rightarrow 0} = \delta_2 \cdot 1 = -0,0480560$$

Hidden-Schicht

$$\delta_1 = \frac{\partial J}{\partial z_1} = (w_{h \rightarrow o} \delta_2) a_1 (1 - a_1)$$

$$a_1 (1 - a_1) = 0,7310586 \cdot 0,2689414 = 0,1966119$$

$$\delta_1 = 1 \cdot (-0,0480560) \cdot 0,1966119 = -0,00944839$$

Gradienten

$$\frac{\partial J}{\partial w_{x \rightarrow h}} = \delta_1 \cdot x = -0,00944839 \cdot 0 = 0$$

$$\frac{\partial J}{\partial w_{b \rightarrow h}} = \delta_1 \cdot 1 = -0,00944839$$

Updates ($w \leftarrow w - \alpha \frac{\partial J}{\partial w}$, $\alpha = 0,01$)

$$w_{b \rightarrow o} = 1 - 0,01 \cdot (-0,0351318) = 1,0003513$$

$$w_{x \rightarrow o} = 2 - 0,01 \cdot (0) = 2,00$$

$$w_{b \rightarrow h} = -2 - 0,01 \cdot (-0,0480560) = -1,9995194$$

$$w_{x \rightarrow h} = -1 - 0,01 \cdot (0) = -1,00$$

$$w_{b \rightarrow h} = 1 - 0,01 \cdot (-0,00944839) = 1,0000945$$